

*Títol:* BibT<sub>E</sub>X Bibliography Index Maker

*Volum:* 1/1

*Alumne:* Ramon Xuriguera Albareda

*Director/Ponent:* Marta Arias

*Departament:* LSI

*Data:* Primavera 2010



---

## DADES DEL PROJECTE

*Títol del Projecte:*

*Nom de l'estudiant:* Ramon Xuriguera Albareda

*Titulació:* Enginyeria Informàtica

*Crèdits:* 37,5

*Director/Ponent:* Marta Arias

*Departament:* LSI

---

## MEMBRES DEL TRIBUNAL *(nom i signatura)*

*President:*

*Vocal:*

*Secretari:*

---

## QUALIFICACIÓ

*Qualificació numèrica:*

*Qualificació descriptiva:*

*Data:*

---



# Índex

<b>1</b>	<b>Introducció</b>	<b>7</b>
1.1	Estructura d'aquest document . . . . .	7
<b>2</b>	<b>Definició del Projecte</b>	<b>9</b>
2.1	Context . . . . .	9
2.2	BIBTEX . . . . .	9
2.3	Funcionalitats . . . . .	10
2.4	Disseny del sistema . . . . .	10
2.5	Llista de tasques . . . . .	11
<b>3</b>	<b>Cerca de referències</b>	<b>13</b>
3.1	Extracció dels continguts d'un PDF . . . . .	13
3.1.1	Dificultats . . . . .	14
3.1.2	Programari . . . . .	14
3.2	Consultes . . . . .	15
3.3	Cercadors . . . . .	16
3.3.1	Ordenació de resultats . . . . .	16
3.3.2	Altres Ajustaments . . . . .	16
3.4	<i>Multithreading</i> . . . . .	17
<b>4</b>	<b>Extracció de referències</b>	<b>18</b>
4.1	<i>Wrappers</i> . . . . .	18
4.1.1	<i>Reference Wrappers</i> . . . . .	19
4.1.2	<i>Field Wrappers</i> . . . . .	19
4.2	Validació de referències . . . . .	20
4.3	Format de referències . . . . .	22
4.4	Emmagatzematge . . . . .	22
<b>5</b>	<b>Generació de <i>Wrappers</i></b>	<b>23</b>
5.1	Obtenció d'exemples . . . . .	23
5.2	Generació automàtica de regles . . . . .	24
5.2.1	<i>Path Rules</i> . . . . .	24
5.2.2	<i>Regex Rules</i> . . . . .	26
5.2.3	Regles multi valor . . . . .	27
5.3	Avaluació dels <i>wrappers</i> . . . . .	30

## *Índex*

<b>6</b>	<b>Anàlisi de resultats</b>	<b>31</b>
6.1	Cerca de referències . . . . .	31
6.2	Generació de <i>wrappers</i> . . . . .	33
6.3	Extracció de referències . . . . .	36
<b>7</b>	<b>Conclusions i Treball Futur</b>	<b>39</b>
7.1	Objectius Assolits . . . . .	39
7.2	Possibles Millores . . . . .	39
<b>A</b>	<b>Biblioteques utilitzades</b>	<b>41</b>
<b>B</b>	<b>Diagrames</b>	<b>43</b>
<b>C</b>	<b>Extracció Contingut PDF</b>	<b>46</b>
<b>D</b>	<b>Resultats dels tests</b>	<b>47</b>
D.1	Generació de <i>wrappers</i> . . . . .	47
<b>E</b>	<b>Manual d'usuari</b>	<b>50</b>
E.1	Referències . . . . .	50
E.2	<i>Wrappers</i> . . . . .	53

# Capítol 1

## Introducció

El format PDF ha esdevingut un estàndar per la divulgació de publicacions on-line.

Actualment existeixen serveis com ara *Google Scholar*, *Microsoft Academic Search* o *CiteSeer* que es dediquen a recol·lectar informació sobre articles i que comptabilitzen les referències entre diferents publicacions. En el cas de *CiteSeer*, al ser un projecte lliure, sabem que funciona analitzant les diferents parts dels articles, com ara les cites, però que també té problemes per obtenir els camps de la capçalera, que és el que ens interessa [GBL98].

Per una altra banda, també existeixen nombroses aplicacions dedicades al maneig de referències com *JabRef*<sup>1</sup> o *Mendeley*<sup>2</sup>. Entre algunes de les funcionalitats addicionals que ofereixen, hi ha la possibilitat de cercar en bases de dades d'articles i utilitzar les meta-dades dels fitxers per tal de trobar informació com ara el títol o l'autor. A banda d'això, no n'hem trobat cap que aprofiti el contingut dels documents per generar la referència.

El nostre sistema mira d'omplir el buit que queda entre aquestes dos tipus de programari que *BIB<sub>T</sub>E<sub>X</sub> Bibliography Index Maker* és una eina d'ajuda a la creació d'índexs bibliogràfics pensada com un complement a aplicacions de maneig de referències ja existents com poden ser .

La principal funcionalitat que ofereix consisteix en escanejar un directori que conté articles científics en PDF i generar un índex bibliogràfic en *BIB<sub>T</sub>E<sub>X</sub>* amb les referències d'aquests fitxers. Aquest índex es pot importar des de les aplicacions esmentades o bé pot ser referenciat directament des d'un nou document *T<sub>E</sub>X*.

Compta amb tres parts principals:

### 1.1 Estructura d'aquest document

La memòria està dividida en els set capítols següents:

- Capítol 2: Descripció formal del projecte així com un repàs sobre el disseny.
- Capítol 3: Parla de les tècniques que s'utilitzen per poder aconseguir pàgines que continguin informació sobre els do

---

<sup>1</sup><http://jabref.sourceforge.net>

<sup>2</sup><http://www.mendeley.com>

## Capítol 1. Introducció

- Capítol 4: Tracta sobre com extreure la informació sobre els articles de les pàgines d'Internet que hem obtingut.
- Capítol 5: Està dedicat a les tècniques per generar, de forma automàtica, les regles d'extracció de les referències.
- Capítol 6: Plantejament de les proves per cadascuna de les parts més importants del sistema i anàlisi dels resultats obtinguts.

Pel que fa al contingut de les diferents seccions, ens hem volgut centrar, sobretot, en el que fa a les decisions que hem hagut de prendre al llarg de la realització del projecte i no tant en els aspectes tècnics de com s'ha implementat el sistema. Per cada decisió es presenten algunes de les opcions plantejades en un principi, els problemes que aquestes presenten i es passa a descriure la solució escollida i els motius de l'elecció.

S'assumeix que es tenen nocions bàsiques de l'estructura dels documents HTML i d'expressions regulars, dos temes que no es tractaran. Pel que fa a les expressions regulars, s'utilitzen les operacions que ofereix el mòdul `re` de *Python*. Es pot trobar més informació a [Pytb].



## Capítol 2

# Definició del Projecte

### 2.1 Context

textasdf

Aomwe

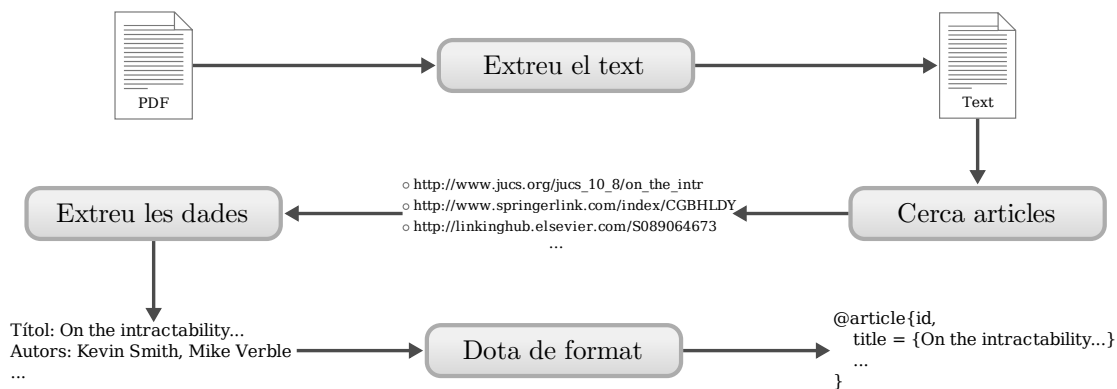


Figura 2.1: Esquema del procés a seguir per extreure una referència

dls

### 2.2 BibTeX

Per poder entendre el context del projecte cal que descrivim l'eina de maneig de referències BibTeX i la sintaxi del llenguatge que utilitza. En el nostre cas farem servir aquest llenguatge com a format de sortida al generar els índexs bibliogràfics. Al llistat 2.1 es mostra un exemple d'una referència d'un article científic expressat en el format BibTeX:

```
@article{MoSh:27,  
title = {Size direction games over the real line},
```

```
author = {Moran, Gadi and Shelah, M., Saharon},
journal = {Israel Journal of Mathematics},
pages = {442--449},
volume = {14},
year = {1973},
}
```

Llistat 2.1: Referència expressada en BibTeX

Alguns aspectes a comentar sobre l'exemple anterior:

- La primera línia conté el tipus de document i un identificador. El primer defineix els camps obligatoris que s'han d'especificar, i el segon ens permetrà citar a la referència des d'un document. En el nostre cas només ens interessen les referències de tipus *article* i haurem de definir, com a mínim, els camps *author*, *title*, *journal* i *year*, que són obligatoris.
- Es considera que el nom d'un autor o editor pot constar de quatre parts diferents: *First*, *von*, *Last*, *Jr.*. Es poden ordenar de diverses maneres, però nosaltres ho farem amb `<von>` `<last>`, `<middle>`, `<first>`. Cal separar múltiples noms amb la paraula **and**.
- L'últim camp d'una referència pot acabar o no amb una coma.

## 2.3 Funcionalitats

A continuació es llisten totes les funcionalitats que l'aplicació ofereix a l'usuari final:

- Extracció de la referència bibliogràfica corresponent a un o més articles que es troben en fitxers PDF en algun directori.
- Possibilitat d'exportar les referències extretes en format BibTeX i desar-les a un fitxer `.bib`
- Generació automàtica de regles d'extracció a partir d'exemples.
- Importació de referències en un fitxer `.bib` per tal de poder-los fer servir d'exemples.
- Totes les operacions CRUD per a la gestió de referències i regles d'extracció.

## 2.4 Disseny del sistema

Hem organitzat el codi del sistema en els mòduls que es llisten a continuació:

- *Raw Content Extraction* (rce): Agrupa totes les classes encarregades d'extreure el contingut dels documents PDF.
- *Information Retrieval* (ir): Encarregat de comunicar-se amb els diferents cercadors disponibles a Internet per obtenir pàgines que contenen informació de la referència que volem extreure.
- *Information Extraction* (ie): Conté tot el codi que permet obtenir la referència a partir d'una pàgina HTML. A més, també és l'encarregat de generar nous *wrappers*.
- *References*: Per una banda fa un anàlisi sintàctic de les referències extretes per poder-les validar. Per l'altra, transforma a BibTeXles referències extretes.

- Base de dades (db): Tal i com indica el seu nom, duu a terme els accessos la base de dades.
- *Main*: Enllaça tots els mòduls anteriors i proporciona punts d'entrada a la interfície d'usuari. Fa de façana del sistema.
- *Graphical User Interface* (gui): Interfície d'usuari més o menys amigable.

La figura 2.2 mostra com interaccionen entre ells.




Figura 2.2: Mòduls del sistema

## 2.5 Llista de tasques

A continuació es llisten les diferents tasques que s'han dut a terme durant la realització del projecte:

Tasca
<p>Recerca i proves de concepte</p> <p>Infraestructura (repositori, <i>build tracker</i>, etc.)</p> <p>Extracció del text dels PDF (<b>bibim.rce</b>)</p> <ul style="list-style-type: none"> <li>Comparació de resultats entre les diferents eines</li> <li>Tria de l'eina d'extracció</li> </ul> <p>Obtenció de pàgines amb la referència (<b>bibim.ir</b>)</p> <ul style="list-style-type: none"> <li>Obtenir consultes del text</li> <li><i>Browser</i> per obtenir pàgines de la Web</li> <li>Ús de les APIs dels cercadors</li> <li>Cerca de les consultes (múltiples cercadors)</li> <li>Ordenació resultats de la cerca</li> </ul> <p>Extracció d'informació (<b>bibim.ie</b>)</p> <ul style="list-style-type: none"> <li>Anàlisi de l'estructura d'algunes biblioteques digitals disponibles</li> <li><i>Wrappers</i> a mà per extreure referències directament</li> <li><i>Wrappers</i> a mà per extreure camps</li> <li>Validació de les referències extretes</li> </ul> <p>Generació automàtica de <i>wrappers</i></p> <ul style="list-style-type: none"> <li>Extracció d'exemples</li> <li>Generació de regles</li> <li><i>Wrapper</i> genèric</li> </ul>

Tractament de referències ( <b>bibim.references</b> )
<i>Parsing</i>
Generació
Crear índexs
Base de dades ( <b>bibim.db</b> )
Disseny      Mòdul principal ( <b>bibim.main</b> )
Escaneig de fitxers
Codi principal de l'aplicació
<i>Threading</i>
Validació de referències
Interfície d'usuari ( <b>bibim.ui</b> )
Editor de referències
Editor de <i>wrappers</i>

## Capítol 3

# Cerca de referències

### 3.1 Extracció dels continguts d'un PDF

El primer pas per aconseguir els objectius proposats és l'extracció del contingut d'un fitxer PDF. Aquest és un dels aspectes que han influït més en l'enfocament que hem donat al sistema, pels motius que es descriuen a continuació.

En un principi, la solució que vam plantejar va ser intentar extreure la referència bibliogràfica d'un document directament del fitxer PDF del qual es disposa. Tot i que a simple vista ja es veu que això pot tenir limitacions (e.g. informació que no es troba dins del text), després de veure com queden els articles al convertir-los a text ens vam allunyar encara més d'aquesta idea.

```
Characterization and Armstrong Relations for Degenerate
Multivalued Dependencies Using Formal Concept Analysis
Jaume Baixeries and Jos' Luis Balc'zar e a
Dept. Llenguatges i Sistemes Inform'tics , a Universitat
Polit 'cnica de Catalunya, e c/ Jordi Girona, 1-3, 08034
Barcelona {jbaixer , balqui}@lsi.upc.es

Abstract. Functional dependencies , a notion originated ...
```

Llistat 3.1: Text corresponent a la capçalera d'un article després d'haver-lo extret d'un PDF

Els llistats 3.1 i 3.2 mostren exemples de les capçaleres de dos articles diferents després d'haver extret el text del fitxer PDF en el que es trobaven. Com es pot veure, el resultat no té cap tipus d'estructura que pugui deixar intuir quina part del text correspon a cada fragment d'informació, sinó que és un conglomerat de totes dades. El primer article comença amb el títol i segueix amb els noms dels dos autors i la informació de la universitat. En canvi, el segon comença amb l'any, la conferència on s'ha presentat, títol i per cada autor es dona informació diferent sobre la universitat. Si comencem a mirar més articles, el número de casos amb estructures diferents no para d'augmentar.

```
2010 Second International Conference on Future Networks

Cloud Computing Research and Development Trend
```

```
Shuai Zhang Hebei Polytechnic University College of Science  
Hebei Polytechnic University NO.46 Xinhua West Street  
Tangshan 063009, Hebei Province China zhangshuai@heut.  
edu.cn Xuebin Chen Hebei Polytechnic University College  
of Science Hebei Polytechnic University NO.46 Xinhua  
West Street Tangshan 063009, Hebei Province China  
chxb@qq.com  
Abstract—With the development of parallel computing,  
distributed [...]
```

Llistat 3.2: Un altre exemple de text extret d'un PDF

Una vegada vistos els resultats, probablement quedin més clars els motius pels quals hem decidit consultar la informació dels articles que hi ha disponible a la xarxa. De totes maneres, continua sent necessària l'extracció del text dels PDFs per tal de poder fer cerques, i ara cal veure, doncs, com ho podem fer.

### 3.1.1 Dificultats

Tot hi haver-hi diverses utilitats que permeten l'extracció del contingut d'un fitxer PDF en forma de text pla o HTML, totes presenten problemes similars als que es descriuen a continuació. Les principals dificultats que es troben a l'hora d'obtenir el text són:

- Caràcters especials com ara Unicode o lligadures (e.g. *fi* es representa com un sol caràcter)
- Sub/Superíndexs: la majoria d'eines els extreuen com text que forma part de la paraula. Per exemple: *Joan*<sup>3</sup> s'extreu com a *Joan3*
- Flux del text dins del fitxer: Hi ha casos en que el text es troba en diferents columnes i a l'hora d'extreure'l a aquestes columnes o seccions no han d'estar mesclades.
- Fragmentació de paràgrafs: Relacionat amb el punt anterior. Hi ha ocasions on els paràgrafs es divideixen en un conjunt de línies segons com es troben posicionades dins del document. El text resultant conté salts de línia addicionals que s'han introduït per conservar les mateixes línies del document original, sense tenir en compte l'estructura real.
- Fitxers protegits dels quals no es pot extreure el contingut

Una altra situació en què no serem capaços d'extreure el text del PDF és quan el text ha estat escanejat i els fitxers PDF només contenen imatges. Pel que hem vist, això sol passar sobretot per articles de fa uns quants anys. Aquest tipus de fitxers no es tractaran en aquest projecte.

### 3.1.2 Programari

El llistat de programari lliure disponible per a dur a terme l'extracció del contingut és força reduït. Tot i així, hem tingut en compte diverses opcions abans d'escollir una biblioteca o aplicació d'extracció. Hem contemplat: *PyPDF*, *PDFMiner*, *PDFBox* i finalment ens hem decantat per *xPDF*.

*xPDF* és un conjunt d'eines executables des de la línia de comandos que permeten extreure text i altres elements dels fitxers PDF. Es distribueixen sota la llicència GPL v.2 i hi ha binaris tant per Windows com per Linux (que també funcionen per Mac OS). El motiu principal pel qual hem escollit aquesta eina és que s'obtenen resultats relativament bons. En especial, és interessant el fet que no separa els paràgrafs en diferents línies i que en la majoria dels casos respecta el flux del text dins del document.

Pel que fa als caràcters especials, transforma bé les lligadures en múltiples caràcters, però té problemes amb la codificació Unicode. Donat que la majoria dels articles científics estan escrits en anglès, aquest és un problema que hem decidit obviar. Tal i com veurem, a no ser que l'article contingui un percentatge molt elevat d'aquest tipus de caràcters, serà igualment possible extreure'n la referència.

## 3.2 Consultes

El més important per poder cercar referències bibliogràfiques a Internet és ser capaços de generar consultes que retornin bons resultats. Per fer-ho, agafarem porcions del text extret amb l'eina *xPDF* i les utilitzarem per obtenir resultats que hi coincideixin exactament.

Una primera idea pot consistir en cercar segons el títol de la publicació de la qual volem informació. El problema és que bona part dels resultats corresponen a pàgines que fan una referència a aquesta publicació, però que no en donen gaires detalls. Pel que fa a la resta d'informació de la capçalera (e.g. autors, revista, etc.) les consultes encara seran menys restrictives i retornaran resultats pitjors. Per una altra banda, si intentem fer consultes a partir del contingut del propi article ens trobem amb que en molts casos, els cercadors no el tenen indexat.

Una tercera opció, que és la que utilitzem, consisteix en generar les consultes a partir del resum o *abstract* que acompanya a la majoria d'articles i que també acostuma a aparèixer a les pàgines que contenen la referència. Però com podem saber quina part del text que hem extret correspon al resum? Tot i que en moltes vegades el primer paràgraf va precedit de la paraula *Abstract*, també n'hi ha moltes altres que van precedits d'una paraula completament diferent (e.g. resum o *summary*) o bé per cap. Per tal que el sistema sigui el més general possible, enlloc de fixar-nos en paraules concretes fem servir una expressió regular molt simple que permet trobar cadenes amb un número de paraules determinat.

Un dels trets característics de les capçaleres dels articles una vegada n'hem extret el text és que contenen un nombre elevat de símbols especials. Això ens pot ajudar a distingir entre les parts corresponents a la capçalera i resum. L'expressió regular que obté les consultes és:  $([\backslash w()?!]+[ ])\{min,max\}$  i agafarà seqüències de *min* a *max* paraules separades per un espai i formades per caràcters alfanumèrics i un nombre limitat de símbols. Els paràmetres *min* i *max* són configurables. Òbviament, les consultes que ens dona aquesta expressió no sempre són bones i per tal de contrarrestar aquests errors, en generem varies i les anem utilitzant mentre no s'obtinguin resultats satisfactoris. De totes maneres, tal i com es pot veure al capítol 6, no és necessari ni generar moltes consultes ni cal que aquestes siguin gaire llargues.

A continuació es llisten cinc consultes extretes d'un article d'exemple. Noteu que s'envolten de cometes dobles, la forma habitual d'indicar als cercadors que les coincidències han de ser exactes.

- “are known to admit interesting characterizations in terms of Formal”
- “natural extensions of the notion of functional dependency are the”
- “We propose here a new Galois”
- “which gives rise to a formal concept lattice corresponding precisely”
- “o the degenerate multivalued dependencies that hold in the relation”

En molts casos, l'expressió regular anterior també dona coincidències pel títol de l'article. Per evitar el problema que hem descrit, hi ha definit un altre paràmetre que estableix el nombre de consultes a saltar-se des del principi de l'article. És una manera rudimentària d'aconseguir-ho, però funciona la majoria de vegades.

### 3.3 Cercadors

El següent pas després d'haver obtingut un conjunt de consultes és utilitzar-les amb un cercador per tal d'obtenir pàgines amb informació de la referència que volem aconseguir. Al capítol d'introducció, hem esmentat que hi ha cercadors com ara *Google Scholar* o *Microsoft Academic Search* on els resultats només corresponen a publicacions. En un principi ens va semblar raonable intentar fer ús d'aquests serveis per poder aconseguir els nostres objectius. El problema és que no tenen cap API publicada que permeti fer consultes automàtiques des d'aplicacions de tercers. Tot i que hi ha solucions a aquest problema, van en contra dels termes i condicions i els servidors bloquegen massa consultes seguides. Per tant, hem descartat aquesta opció.

Així doncs, ens quedem amb els cercadors habituals i hem preparat la nostra aplicació per tal d'utilitzar les APIs de *Google*, *Yahoo* i *Bing*. Tots tres cercadors retornen els resultats en format JSON. Els principals inconvenients són que retornen qualsevol tipus de pàgina i que no tenen indexades algunes biblioteques digitals. Tot i així, també podem aconseguir bons resultats amb l'ús de les consultes adequades. Al capítol de resultats (6.1) hi ha una comparativa.

#### 3.3.1 Ordenació de resultats

La majoria de vegades, no ens convindrà l'ordre dels resultats donat pels diferents cercadors sinó que voldrem processar les pàgines segons aquelles per les quals tenim regles d'extracció. És per això que un cop hem consultat al cercador, comprovem si tenim regles per alguna de les pàgines resultants i, en cas afirmatiu, la movem a dalt de tot de la llista.

En cas d'haver-hi múltiples pàgines de les quals sabem extreure les dades, ho farem segons una puntuació assignada a les regles de les que disposem. Aquest tema de les puntuacions es tracta amb més detall al capítol sobre generació de *wrappers* (5).

#### 3.3.2 Altres Ajustaments

Depenent de l'estructura del contingut dels fitxers dels que disposem, la qualitat dels resultats obtinguts amb els cercadors pot variar considerablement. Això suposa la necessitat d'ajustar alguns paràmetres per tal de poder adaptar el sistema a l'ús de cadascú. A la secció sobre la generació de consultes (3.2), ja hem comentat la possibilitat d'ajustar el mínim i màxim de termes a cercar, però hi ha altres opcions que es poden configurar.



En algunes ocasions, es dona el cas que la consulta generada no és prou restrictiva, ja sigui perquè no és prou llarga o bé perquè està formada per paraules molt generals. Al cercar amb aquestes consultes s'obté una llarga llista de resultats, la majoria dels quals no tenen res a veure amb la informació que estem buscant. Per contrarestar-ho, hi ha la possibilitat d'indicar al sistema que ometi els resultats i provi amb la següent consulta. A l'hora d'assignar el valor d'aquest paràmetre, també s'haurà de tenir en compte el tipus d'articles dels que es vol informació. Per exemple, articles populars tindran un número de coincidències rellevants gran i, per tant, haurem d'assignar un valor relativament alt, ja que un valor baix farà que descartem resultats bons. En canvi, per articles poc corrents, ens interessarà el contrari.

Per una altra banda, hi ha ocasions en que els cercadors tenen tendència a retornar resultats que, tot i coincidir amb la consulta que li hem donat, corresponen a una pàgina que no ens aporta massa informació. Per tal d'ajudar a l'aplicació a descartar resultats dolents, podem indicar-li pàgines que volem ometre a partir d'una llista negra. Per exemple, sabem que les pàgines sobre els autors de la biblioteca digital *ACM Portal* contenen un llistat de tots els articles d'un mateix autor, però que no contenen suficient informació com per extreure referències. En aquest cas voldrem descartar els resultats que comencen per [http://portal.acm.org/author\\_page.cfm?id=id-autor](http://portal.acm.org/author_page.cfm?id=id-autor).

### 3.4 Multithreading

Un dels inconvenients més grans que implica el fet d'haver d'accedir a Internet, és que el temps perdut esperant dades és molt alt. Per reduir-lo, s'ha estudiat la possibilitat d'utilitzar diferents fils d'execució per fer més d'una consulta de forma més o menys simultània. La taula següent mostra una comparativa del temps necessari per obtenir múltiples pàgines web de forma seqüencial o bé utilitzant fins a cinc fils d'execució diferents. Les pàgines corresponen a consultes aleatòries a *Google* per evitar l'efecte dels *proxies* i *caches*.

2 pàgines		5 pàgines		10 pàgines		20 pàgines	
Seq.	5 Threads	Seq.	5 Threads	Seq.	5 Threads	Seq.	5 Threads
0.9010	0.5481	2.1830	0.6612	4.3153	1.5914	7.9295	2.5949
0.7467	0.3795	2.1558	0.7441	4.3186	1.2311	8.5483	2.1958
0.7678	0.5641	2.0645	0.5383	9.2930	1.4415	8.7202	2.5749
0.7421	0.3876	2.0684	0.8551	4.9859	1.5294	8.4732	2.2841
0.9674	0.5477	2.1510	0.8550	5.3600	1.3116	9.2901	2.2257
Mitjana:							
0.8250	0.4854	2.1246	0.7307	5.6546	1.4210	8.5923	2.3751
Guany:							
<b>-44.96%</b>		<b>-65.6%</b>		<b>-74.87%</b>		<b>-72.35%</b>	

Tot i que aquestes proves no són riguroses, sí que són suficients per poder-nos fer una idea força clara sobre la millora que s'obté utilitzant múltiples fils respecte no fer-ho.

Pel que fa a la forma d'implementar-ho, hem creat un *pool* amb un número màxim configurable de fils d'execució que es van reutilitzant mentre queden referències per extreure. Bàsicament, tenim una cua amb les rutes als fitxers PDF i una cua de sortida amb el resultat d'extreure les referències. Cada *thread* va processant fitxers de la cua d'entrada mentre aquesta no és buida. El número de fils s'haurà d'ajustar segons del tipus de connexió del que es disposi.

## Capítol 4

# Extracció de referències

Un cop hem aconseguit trobar pàgines que contenen informació de l'article pel qual volem generar la referència bibliogràfica, és moment d'extreure aquesta informació i formatar-la. En aquest capítol tractarem els problemes que hem trobat a l'hora d'extreure la in

### 4.1 *Wrappers*

En el nostre context, anomenarem *wrapper* a una classe que implementa una sèrie de mètodes establerts i que, a partir d'un text o document d'entrada, permet extreure'n certa informació. Podem imaginar-ho com un filtre que només ens deixa veure una part del document que ens interessa.




Figura 4.1: Exemple de la funció d'un *wrapper*

Internament, consisteixen en un seguit de regles que saben com extreure les dades de documents amb una estructura concreta. A la nostra aplicació tindrem els dos tipus de *wrapper* que es descriuen a continuació.

### 4.1.1 Reference Wrappers

Aquest tipus de *wrappers* extreuen el text corresponent a una referència sencera dins de les pàgines HTML dels resultats. El gran avantatge que tenen és que habitualment permeten extreure molta informació i amb una confiança molt més gran. Ara per ara, el sistema només suporta referències B<sub>I</sub>B<sub>T</sub><sub>E</sub>X, però es podria ampliar amb qualsevol altre format.




Figura 4.2: Esquema de funcionament dels *reference wrappers*

El principal problema és que s'han d'implementar manualment ja que moltes vegades el text de les referències no es troba a la mateixa pàgina retornada pels cercadors, sinó que cal seguir algun enllaç o realitzar altres accions abans d'arribar-hi, cosa que complica força la generació automàtica. A més, el fet que d'aquests *wrappers* només en necessitem un per cada biblioteca, fa que no s'hagi considerat oportú automatitzar-ne la generació ja que (de moment) no suposa un estalvi de recursos prou gran.

Un altre inconvenient d'aquest tipus de *wrappers* és que hi ha moltes biblioteques digitals que no ofereixen les referències en B<sub>I</sub>B<sub>T</sub><sub>E</sub>X sinó en altres formats com ara *RIS*, *MODS*, etc. Els formats que s'ofereixen depenen força del camp de coneixement en què s'especialitza la biblioteca.

Respecte a la manera d'implementar-los, cal estudiar el funcionament de cada biblioteca i aplicar una mica d'enginyeria inversa. Per exemple, en algunes ocasions podem aconseguir alguna drecera per arribar a les referències a partir de les direccions retornades pels cercadors. Un dels casos més senzills és el de la biblioteca digital *ScientificCommons* on per obtenir el codi B<sub>I</sub>B<sub>T</sub><sub>E</sub>X només hem de canviar l'adreça retornada pel cercador:

Canviem ...  
<http://en.scientificcommons.org/32119993>  
 per ...  
<http://en.scientificcommons.org/export/bibtex/32119993>

Llistat 4.1: Adreça d'un article de *ScientificCommons*

Altres vegades, obtenir la referència és més complicat, i és necessari construir l'adreça a partir de paràmetres d'una crida a una funció *JavaScript*, com passa per la biblioteca *ACM*; o bé a partir de camps d'un formulari, cas de *ScienceDirect*, etc.

### 4.1.2 Field Wrappers

A diferència dels que acabem de veure, aquest tipus de *wrappers* s'especialitzen en extreure únicament un dels camps de la referència cada vegada. Per tant, se'n necessita un per cadascun dels camps que volem obtenir per cada biblioteca d'articles que vulguem suportar. El diagrama següent mostra la diferència entre aquest tipus de *wrappers* respecte els de la figura 4.2:

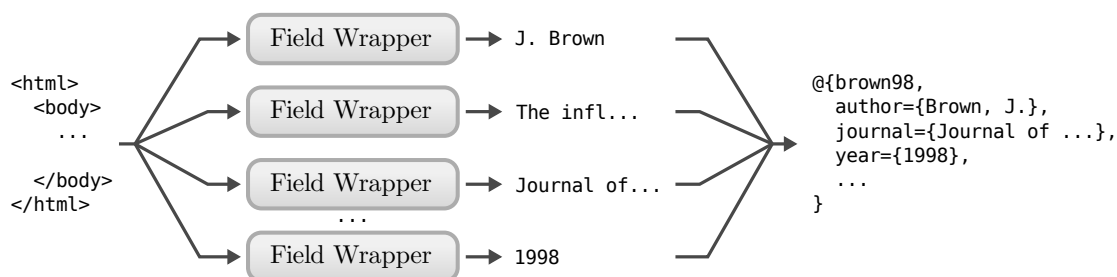


Figura 4.3: Esquema de funcionament dels *field wrappers*

Internament, aquests tipus de *wrappers* consisteixen en un llistat de regles que cal aplicar en un ordre determinat i que, si tot va bé, donen com a resultat el valor que volem aconseguir. Aquestes regles estan connectades en cascada, de manera que el tipus de sortida d'una regla ha de ser vàlida per l'entrada de la següent.

Per assegurar-nos que l'aplicació pot aconseguir els objectius proposats, en un principi vam començar a definir algunes d'aquestes regles manualment, mirant de fer-les prou generals com per poder-les reutilitzar per múltiples biblioteques. És fàcil veure que aquesta és una tasca que consumeix molt temps. A més, s'ha de tenir en compte que els resultats obtinguts es veuen afectats per qualsevol canvi en l'estructura de les pàgines font. Cada vegada que hi ha un redisseny, s'han d'actualitzar les regles o bé crear-les de nou. Per tant, vam decidir dedicar la resta de projecte en trobar la manera de generar aquest tipus de *wrappers* de forma automàtica. La forma de fer-ho es descriu al capítol 5.

Si ens centrem en el procés d'extracció, els passos que se segueixen són:

- Donat el resultat web d'un article mirem si disposem de *wrappers* per algun dels camps a la base de dades de l'aplicació.
- De ser així, per cada camp obtenim els millors segons una puntuació.
- Apliquem el *wrapper*
- Si el resultat es considera vàlid, passem al següent camp. Altrament, provem amb un altre *wrapper*.

Com es pot deduir, no serà necessari tenir *wrappers* que funcionin en tots els casos sinó que només caldrà tenir-ne uns quants que ho facin en un percentatge prou elevat. Això facilita l'extracció per les biblioteques digitals varien l'estructura de la informació en algunes ocasions.

## 4.2 Validació de referències

Després d'obtenir les dades dels documents HTML amb els mètodes indicats, ens interessa validar-les per diversos motius:

- Continuar provant més resultats i regles disponibles abans de donar l'extracció per finalitzada.

- Indicar a l'usuari que sospitem que algun dels camps no és correcte.
- Avaluar els *wrappers* per tal d'eleger els millors en properes extraccions.
- Evitar utilitzar referències incorrectes a l'hora de generar nous *wrappers*

El procés de validació de les dades depèn de cada camp i és totalment ajustable. Dins del fitxer de configuració de l'aplicació, es pot establir, per cada camp com s'ha de validar i un pes sobre la validesa total de la referència. Pel que fa al primer paràmetre, tindrem diferents tipus de validadors:

- *WithinTextValidator*: Basa la validació en comprovar si la cadena extreta es troba dins del text extret de l'article PDF.
- *PersonValidator*: Semblant a l'anterior, però ho comprova pels diferents noms de les persones.
- *RegexValidator*: Mira que el text extret coincideixi amb una expressió regular que també s'inclou al fitxer de configuració. Útil per aquells casos on el camp no es troba dins del document de l'article (e.g. pàgines, issn).

El pes correspon a un nombre en coma flotant que ens permet donar més importància a certs camps com ara el títol o nom dels autors a l'hora d'indicar com de vàlida és una referència. La suma total dels pesos ha de ser igual a 1.

Per configurar la validació s'utilitza el valor `field_validation` dins del fitxer de configuració. La sintaxi per definir com validar cadascun dels camps és `<field>; <weight>; <validator>; [<validator params>]`. A continuació es mostra un exemple:

```
field_validation=
  title;    0.3; WithinTextValidator
  journal;  0.2; WithinTextValidator
  author;   0.2; PersonValidator
  pages;    0.1; RegexValidator;    \d+(?:\ ?[-,]?\ ?\d+)?
  issn;     0.0; RegexValidator;    (\d{4}-\d{3}(\d|X))
  ...
```

Llistat 4.2: Configuració de la validació de referències

Per anar bé, cal especificar un validador per cadascun dels camps, fins i tot per aquells als que es dona pes 0.0. Això garanteix que els *wrappers* per aquests camps es continuïn avaluant tot i no tenir-los en compte a l'hora de considerar la referència com a vàlida.

### **Parsing de referències**

Per poder validar les referències extretes amb dels *reference wrappers*, és necessari analitzar-les sintàcticament obtenir-ne els diferents camps per separat i poder-los validar. Per aquest motiu, l'aplicació disposa d'un *parser* de referències en format Bib<sub>T</sub><sub>E</sub>X.

### 4.3 Format de referències

Tal com s'ha indicat al diagrama de la figura 2.1, un cop tenim les dades extretes cal donar-los-hi format per poder-les exportar en  $\text{BIB}_{\text{TEX}}$ . Com a detalls de la implementació, només comentar que tenim un jerarquia de classes anomenades *generadors* que, guiades per una classe formatadora (**Formatter**) permetran generar les referències en el format desitjat.

### 4.4 Emmagatzematge

Totes les referències extretes s'emmagatzemen a la base de dades de l'aplicació per poder-les utilitzar en un futur tant per

A part de la referència en si, també es desa la consulta extreta del PDF per cercar a Internet i el resultat de la pàgina de la qual s'ha extret la referència.

## Capítol 5

# Generació de *Wrappers*

En aquest capítol s'expliquen les tècniques utilitzades per la generació automàtica de regles d'extracció de la informació. A grans trets, el procediment a seguir consisteix en agafar exemples de referències i mirar on es troba cada camp dins de la pàgina que conté la referència, per tal d'aplicar-ho en altres pàgines amb la mateixa estructura. Cal comentar que com que els resultats no seran perfectes, l'usuari sempre podrà corregir els *wrappers* generats per maximitzar la correctesa de les dades extretes en cada cas.

### 5.1 Obtenció d'exemples

Per poder generar *field wrappers*, es necessiten exemples del camp que es vol extreure. Un exemple està format pel valor que volem obtenir i pel context en què es troba aquest valor. S'obtenen a partir de les referències emmagatzemades a la base de dades de l'aplicació, que poden haver estat importades d'un fitxer `.bib` o bé extretes anteriorment utilitzant *wrappers* que amb el temps han deixat de funcionar. Totes les referències hauran de tenir associada una URL que apunti a una pàgina que conté la informació de la referència. En el cas de les que s'han obtingut automàticament, aquesta adreça es desa durant l'extracció.

A l'inici, el context dels valors dels nostres exemples és el document HTML de la pàgina que conté la referència. Per tant, el primer pas consisteix en obtenir aquestes pàgines d'Internet. Tot i que per cadascun dels camps es generen *sets* d'exemples diferents, les pàgines són les mateixes i només es descarreguen una sola vegada. Tot i així, com que totes es trobaran a la mateixa biblioteca i les peticions les procesa el mateix servidor, l'aplicació mira d'evitar bloquejos esperant uns segons entre petició i petició. Un cop tenim els exemples generats, mirem si el codi HTML conté la informació que volem extreure i si no és així, l'exemple es marca com a invàlid per tal de no tornar-lo a fer servir en un futur.

El codi HTML es neteja per treure'n els comentaris, salts de línia, i altres elements que no ens interessin, com ara codi *JavaScript* o etiquetes d'estil. El número d'exemples a tenir en compte per generar els *field wrappers* és configurable, però com a mínim es necessiten dos exemples vàlids.

## 5.2 Generació automàtica de regles

Al capítol anterior s'ha explicat que els *field wrappers* estan formats per una llista de regles que s'han d'aplicar en un ordre concret per tal de poder extreure el camp que volem. Per nosaltres una regla està composta per un patró i un procediment que aplica aquest patró; en tenim de diferents tipus segons les dades d'entrada i sortida que reben i retornen. Les regles es connectaran en cascada, de manera que és necessari que el tipus de sortida d'una sigui vàlida per l'entrada de la següent.

Els detalls respecte com es creen varien depenent de cada tipus de regla, però els dos passos bàsics que se segueixen són els següents. Donat un *set* d'exemples:

1. Es generen regles per un dels exemples.
2. Es fusionen les regles obtingudes amb les anteriors.

Donat que volem extreure informació de documents HTML, les regles mínimes que necessitem són: una per localitzar l'etiqueta HTML que conté el valor que ens interessa i una altra per extreure'n aquest valor entre tot el text que pugui acompanyar-lo dins de la mateixa etiqueta. Les hem anomenat *path rules* i *regex rules* respectivament.

### 5.2.1 Path Rules

Tal i com acabem de comentar, són les regles que permeten localitzar trossos d'informació dins de la pàgina. Els patrons consisteixen en una mena de ruta que permet arribar a l'etiqueta HTML que conté el valor del camp. Tenen l'aspecte que es mostra a continuació, formats per una expressió regular i una llista de *triplets* compostos pel nom de l'etiqueta, els seus atributs i la posició respecte els seus *germans*:

```
[ '(\d{4}-\d{3}(\d|X)) ', (u'table ', {u'width': u'100%'}, 7),
  (u'tr ', {}, 0), (u'td ', {}, 0)]
```

Per generar aquests patrons, cerquem el valor que volem extreure dins de l'HTML i anem pujant l'arbre sintàctic que descriu el document fins arribar a un antecessor amb nom d'etiqueta i atributs únics. Per cada element en guardem les seves característiques de manera que després puguem recórrer el mateix camí a l'inrevés.

Pel que fa al número de *sibling* o germà, només l'utilitzem per agilitzar el procés de cerca de la informació a l'hora d'aplicar la regla. En un principi havíem pensat distingir elements segons la seva posició respecte als germans, però això no funciona en aquells casos on múltiples pàgines d'una biblioteca digital mostren la mateixa informació en un ordre diferent. Per exemple, si tinguéssim els dos fragments de codi següents, al cercar el número de volum acabariem amb les rutes simplifiades: [(table, 0), (tr, 1), (td, 0)] i [(table, 0), (tr, 0), (td, 0)]. En realitat, però, ens interessa combinar les dues rutes en una de sola i que ens permeti obtenir l'element correcte en qualsevol dels casos.



<pre> &lt;table&gt;   &lt;tr&gt;     &lt;td class='label '&gt;       Year :     &lt;/td&gt;     &lt;td class='value '&gt;       1985     &lt;/td&gt;   &lt;/tr&gt;   &lt;tr&gt;     &lt;td class='label '&gt;       Volume :     &lt;/td&gt;     &lt;td class='value '&gt;       323     &lt;/td&gt;   &lt;/tr&gt; &lt;/table&gt; </pre>	<pre> &lt;table&gt;   &lt;tr&gt;     &lt;td class='label '&gt;       Volume :     &lt;/td&gt;     &lt;td class='value '&gt;       468     &lt;/td&gt;   &lt;/tr&gt;   &lt;tr&gt;     &lt;td class='label '&gt;       Issue :     &lt;/td&gt;     &lt;td class='value '&gt;       3     &lt;/td&gt;   &lt;/tr&gt; &lt;/table&gt; </pre>
--	--

A l'hora de fusionar dos patrons, només ho fem si coincideixen en la llargada, les etiquetes i els atributs dels elements de la ruta. És a dir, només modifiquem el número de germà: si dues rutes tenen el mateix número, el deixem tal i com està; si difereixen, el substituïm amb el valor  $-1$ . Quan dos o més patrons no es poden fusionar, el que fem és crear *wrappers* diferents amb cadascun d'ells i a l'hora d'aplicar-los, s'escull aquell que en teoria funciona millor.

Mentre apliquem el patró, si veiem un  $-1$  al número de *sibling* fem una cerca de tots els elements d'aquell nivell de l'arbre que compleixen la resta de condicions enlloc d'escollir-ne un directament. Això implica que enlloc d'obtenir un sol element com a resultat, en molts casos en tindrem més d'un. Per exemple, la figura següent mostra el resultat d'aplicar la regla  $[('table', 5), ('tr', -1), ('td', 1)]$  en un document HTML. En aquest cas obtenim els tres elements subratllats. Com pot saber l'aplicació quin dels camps volem?




Figura 5.1: Exemple dels resultats a l'aplicar una *path rule*

Aquí és on entra en joc l'expressió regular de l'inici del patró. Amb aquesta expressió, podem ajudar a l'aplicació a descartar des d'un principi aquells elements que estem segurs que no ens interessaran. En l'exemple anterior, per obtenir l'any, podem tenir definida l'expressió  $(\backslash d\{4\})$  i així quedar-nos només amb el primer element. El patró de la regla en realitat serà:  $[(\backslash d\{4\}), ('table', 5), ('tr', -1), ('td', 1)]$ . Dins del fitxer de configuració es poden definir expressions regulars per cada camp. Com és lògic, en alguns casos ens serà més útil que en altres.

Si estem intentant extreure camps que solen tenir sempre la mateixa forma com ara anys o bé codis com l'ISSN d'un article, serà fàcil indicar-li una expressió. En canvi, pels valors que no tenen cap tipus d'estructura, com ara els noms de revistes, no ens quedarà cap més remei que deixar-ho amb el valor per defecte (.\*)

Un altre avantatge de tenir aquesta expressió regular és que ens servirà per corregir el comportament dels *wrappers* una vegada generats. Per exemple, si veiem que l'any de publicació no s'extreu correctament per una biblioteca determinada amb l'expressió (`\d{4}`), podem restringir més el número de coincidències canviant-la per (`Year\:\ \d{4}`)

### 5.2.2 *Regex Rules*

Aquestes regles permeten extreure un camp quan el valor d'aquest es troba dins d'un element del document HTML acompanyat de més text. Reben una o més cadenes de caràcters com a entrada i els hi apliquen una expressió regular generada automàticament per tal de quedar-se només amb una porció la cadena.

Per generar les expressions regulars, s'agafa el text contingut als elements HTML que ens proporcionen les *path rules* i es fa una substitució del valor que volem obtenir per l'expressió (.\*) . Per exemple, si volguéssim obtenir el número de pàgines d'una pàgina que conté la línia següent, començaríem posant els caràcters d'escapament necessaris i substituint el valor 1204–1209.

```
Vol. 27, No. 6. (1 April 2006), pp. 1204–1209.
```

```
Vol\.\ 27\,\ No\.\ 6\.\ \ (1 April 2006\)\,\ pp\.\ (.*)\.
```

De moment, com que només hem generat l'expressió amb una sola regla, no és prou general per extreure els camps de totes les pàgines. A a mesura que es provi amb més exemples, els trossos de text que varien aniran desapareixent. Suposem que ens arriba un altre exemple i la *path rule* ens retorna la línia següent, per la qual també en generem l'expressió.

```
Vol. 24, No. 1. (2 March 1999), pp. 332–344.
```

```
Vol\.\ 24\,\ No\.\ 1\.\ \ (2 March 1999\)\,\ pp\.\ (.*)\.
```

A simple vista veiem que es tracta de la mateixa part del document HTML que la de l'exemple anterior, i que hauríem de poder aplicar la mateixa expressió regular en els dos casos per tal d'obtenir el número de pàgines. La tècnica que fem servir per decidir si hem de fusionar dues expressions és molt simplista, tan sols avaluem la similaritat de les expressions i comprovem si supera un llindar establert. De ser així, obtenim els blocs no coincidents de les dues cadenes de caràcters i els substituïm per (? : .\*) de manera que s'accepti qualsevol cadena, però que es descarti l'hora d'aplicar l'expressió.

Les comparacions de seqüències es fan amb el mòdul `diff` de la biblioteca estàndard de *Python*. Internament s'utilitza una variant de l'algorisme de reconeixement de patrons de Ratcliff/Obershelp, que mira de trobar la subsequència coincident més llarga tot eliminant els elements no desitjats [Pyta], [RM88]. En l'exemple, el resultat de fusionar les dues expressions és:

```
Vol\.\ (?:.*)\,\ No\.\ (?:.*)\.\ \((?:.*)r(?:.*)\)\,\ pp\.\
(.*)\.
```

Com es pot veure, encara ha quedat la lletra *r* entre dos blocs a descartar. Durant la fusió d'expressions el sistema també aplica heurístiques que ajuden a generalitzar més ràpid. Per exemple, quan troba blocs coincidents de llargada 1, formats per una lletra o un número, els elimina. Per altra banda, també s'agrupen els blocs consecutius a descartar. D'aquesta manera, l'expressió final resultant queda:

```
Vol\.\ (?:.*)\,\ No\.\ (?:.*)\.\ \((?:.*)\)\,\ pp\.\ (.*)\.
```

El mètode que acabem de descriure per generar les expressions regulars no està exempt de problemes. Ja hem vist la necessitat de tenir bons exemples per poder generar expressions prou generals. Una altra situació en que ens podem trobar és que dues seqüències amb la mateixa estructura siguin massa diferents com per decidir fusionar-les. Quan això passa, acabarem amb múltiples expressions molt específiques. Per exemple, “ISSN: 0000-0000, Issue: (.\*)” i “ISSN: 1111-1111, Issue: (.\*)” tenen una similaritat de 0.71. Si el llindar per la fusió fos 0.75, aquests dos patrons es quedarien com estan i acabariem generant dos *wrappers* diferents que segurament no funcionarien per cap altre cas. Veiem doncs, que aquesta tècnica és molt sensible als exemples.

Es podrien aplicar moltes millores per poder convergir a una expressió més general fent servir pocs exemples. En un principi generàvem les expressions de forma creixent, agafant el valor a extreure, i mirant els primers caràcters de la vora (aquesta és una simplificació de com ho feia el sistema *WHISK* [Sod99]). Vam abandonar la idea ja que teníem problemes quan la informació del context també variava entre pàgina i pàgina. En perspectiva, sembla que aquesta idea podria ser aplicada a les expressions que es generen actualment i així acabar amb expressions més curtes i molt més generals. Si ho apliquessim amb els exemples que hem vist en aquesta secció, les expressions resultants serien:

```
\ pp\.\ (.*)\.\
Issue:\ (.)
```

Tot i els problemes, cal tornar a remarcar que l'aplicació permet, en tot moment, l'edició de regles per part de l'usuari. De manera que si una expressió regular no s'ha acabat de generar prou bé, sempre es pot modificar amb un esforç mínim.

### 5.2.3 Regles multi valor

Alguns camps com ara els autors o editors tenen múltiples valors i per poder-los extreure per separat, hem creat variants de les regles que acabem de descriure. Suposem que múltiples valors corresponen al mateix camp si compleixen alguna de les dues condicions següents:

- Es troben en elements HTML diferents, però són germans, cosins o tenen vincle parentiu similar. És a dir, quan les rutes per arribar als valors estan formades pels mateixos elements, però en posicions diferents. Aquesta condició permet extreure valors quan es troben tant en llistes com en taules:

```
<ul>
  <li>
    Liu Jing
  </li>
  <li>
    Li Jiandong
  </li>
  <li>
    Chen Yanhui
  </li>
</ul>
```

Germans

```
<table>
  <tr>
    <td>Autors:</td>
    <td>Liu Jing</td>
  </tr>

  <tr>
    <td></td>
    <td>Li Jiandong</td>
  </tr>
</table>
```

Cosins

- Es troben dins el mateix HTML amb un o més separadors entre ells. Per exemple, els tres autors següents estan separats per les cadenes “,” i “ and ”.

```
<td>Liu Jing , Li Jiandong and Chen Yanhui</td>
```

Llistat 5.1: Exemple múltiples valors

De la mateixa manera que pels camps d'un sol valor, també necessitem obtenir els elements HTML que contenen les dades a extreure. La tècnica és molt similar que la que hem explicat a la secció 5.2.1, l'única diferència és que cal realitzar la fusió addicional dels patrons d'un mateix exemple en les ocasions en que els diferents valors es troben en elements diferents.

Pel que fa a les *regex rules*, el seu equivalent pels *wrappers* multi-valor, és més diferent. Les substituïm per *Separator rules*, *Multi-value regex rules* i *Person rules*:

### **Separator rules**

Són les encarregades de dividir el text d'un únic element en múltiples valors segons una sèrie de separadors. El seu patró consisteix en una llista amb aquests separadors.

El procediment per generar-les és força trivial. Simplement s'agafa el text de l'element retornat per les *path rules*, i se substitueixen els valors que es volen obtenir per alguna cadena que no existeixi dins del text (e.g. l'expressió *(.\*)*).

```
Liu Jing , Li Jiandong , Wai Kwan and Chen Yanhui

(.*) , (.*), (.*), and (.*)
```

Un cop fet això, s'agafen totes les subcadenaes o *separadors* que han quedat entre dels elements substituïts i les fusionem. Aquest procés de *merging* és el mateix que el que se segueix per les expressions de les *regex rules*.

```
[', ', ', ', ' and ' ]

Fusionem:
[' ', ', ', ' and ' ]
```

**Multi-value regex rules**

Funcionen de la mateixa manera que les *regex rules* de l'apartat anterior, però amb la diferència que reben i retornen múltiples valors. L'expressió regular del patró s'aplica per cadascun dels valors de l'entrada. Això permet extreure els valors de forma correcta quan tots, o alguns d'ells, van acompanyats d'altra informació. Per exemple, en el cas de rebre els valors:

```
Liu Jing    – Department of Electrical Engineering
Li Jiandong – Department of Applied Physics
Chen Yanhui – Department of Electrical Engineering
```

Es generarà el patró `(.*)\ \- Department\ of\ (?:(.*)`, de manera que es podran obtenir els noms dels tres autors.

**Person rules**

Només s'apliquen en el cas que els valors del camp siguin noms de persones, com ara els autors i els editors. Aquestes regles reben el nom complet d'una persona i s'encarreguen de separar-lo en diferents parts. Es tenen en compte les parts: *first name*, *middle name* i *last name*. El fet de tenir els noms separats d'aquesta manera permet que a l'hora de formatar la referència (en el nostre cas en  $\text{BIB}_{\text{T}}\text{X}$ ) tots els noms tinguin la mateixa estructura. A continuació es mostren exemples de com quedarien dos noms:

David P. Bartel  <pre>{u'first_name ':   u'David ',   u'middle_name ':   u'P. ',   u'last_name ':   u'Bartel '}</pre>	James Green  <pre>{u'first_name ':   u'James ',   u'middle_name ':   u'',   u'last_name ':   u'Green '}</pre>
---	---

Les regles que acabem de llistar s'han d'aplicar en aquest mateix ordre i, igual que amb la resta de *wrappers*, estaran connectades en cascada:

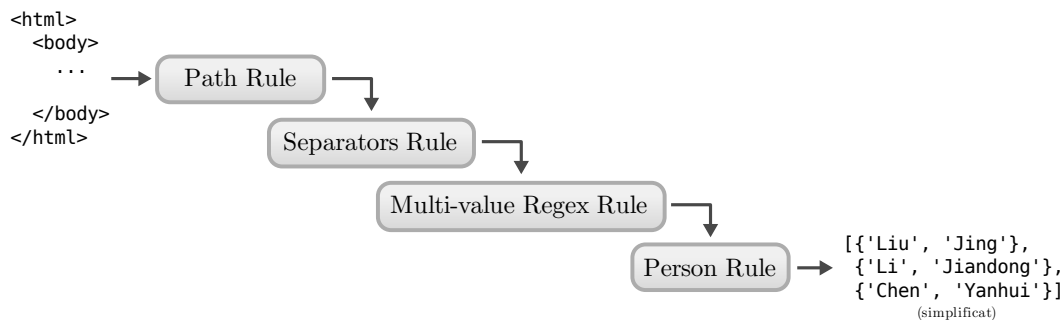


Figura 5.2: Exemple d'extracció de múltiples noms

### 5.3 Avaluació dels *wrappers*

Una vegada hem generat el conjunt dels *wrappers* possibles per a cadascun dels camps, cal que avaluem quins d'ells funcionen millor. Primer, els avaluem amb els mateixos exemples que hem fet servir per la generació. Això ens donarà una idea o confiança sobre com poden arribar a funcionar a l'hora de la veritat i ens guiarà a l'hora d'escollir quins aplicar primer. Durant l'extracció de referències, cada vegada que s'utilitza un *wrapper* s'avalua la informació que ha extret i es corregeix la valoració sobre el funcionament d'aquest *wrapper*.

El sistema d'avaluació és molt senzill, per cadascuna de les vegades que s'extreu informació amb èxit es dona un vot positiu. Si la informació no és correcta, se li'n dona un de negatiu. La puntuació del *wrapper* serà el percentatge de vots positius.

$$score = \frac{vots\ positius}{vots\ totals}$$

Amb aquesta manera de calcular la puntuació, hem de ser conscients sobre què passa quan comparem *wrappers* molt utilitzats amb altres que no ho han estat tant. Per exemple, si tenim un *wrapper* que ha donat bons resultats moltes ocasions durant el passat (i.e. molts vots positius) i comença a fallar, el percentatge decreixerà i de seguida es donarà pas a un altre *wrapper* menys usat, però que no té vots negatius. Per resoldre això, moltes aplicacions usen el *Wilson score interval* descrit a [Mil09] per ordenar elements en casos semblants al nostre.

Aquest comportament que sembla problemàtic és, en certa manera, el que busquem. Quan un *wrapper* que ha funcionat gairebé sempre comença a fallar, és molt probable que ho faci degut a algun canvi en l'estructura de les pàgines de les quals extreu la informació. Si és així, ja sabem que aquest *wrapper* no tornarà a funcionar més i ens interessa descartar-lo tant ràpid com sigui possible. De totes maneres, la fórmula per calcular la puntuació es podria canviar fàcilment si en el futur es comencen a descartar *wrappers* bons.

## Capítol 6

# Anàlisi de resultats

En aquest capítol es mostren les principals proves realitzades per cadascuna de les tres parts del sistema descrites als capítols anteriors. Aquí s'intenten mostrar només una mostra dels resultats obtinguts i alguns casos interessants. La resta es troba a l'apèndix D.

### 6.1 Cerca de referències

En primer lloc provarem com de bé ho fa el sistema a l'hora de cercar pàgines a Internet que continguin informació sobre un article concret. Els tests que hem dut a terme consisteixen en els passos següents:

1. Obtenir una sèrie de consultes per cadascun dels articles d'un llistat de PDFs
2. Cercar cada consulta amb els tres cercadors implementats: *Google*, *Bing* i *Yahoo*
3. Per cada resultat obtingut, analitzem si és bo o no
4. Comptabilitzem el número de consultes que han fet falta per obtenir el primer *bon* resultat

Per tal de classificar els resultats en bons i dolents només comprovem si algunes porcions de la informació que volem es troba dins de la pàgina resultant. Aquesta no és una solució perfecta, però ens permet fer una aproximació sobre la quantitat de fitxers pels quals podem trobar la referència.

Una altra qüestió sobre la implementació dels tests, és que els resultats obtinguts se solen repetir entre consultes del mateix article. Per estalviar temps i evitar fer moltes peticions seguides als mateixos servidors (que podrien resultar en un bloqueig), deixem uns segons entre petició i petició i emmagatzemem cada resultat de manera que només l'hàgim de demanar una sola vegada. A banda d'això, en molts casos els resultats corresponen al mateix fitxer PDF del qual estem buscant informació i els hem d'ometre.

Les proves s'han realitzat per conjunts d'articles diferents agrupats depenent la seva capçalera, que és el que pot fer variar més els resultats obtinguts, i un últim grup amb articles de qualsevol tipus. Els gràfics de les figures 6.1 i 6.2 a mostren els resultats d'aquest últim conjunt.




Figura 6.1: Comparació de la qualitat dels resultats obtinguts segons la llargada de les consultes

El primer gràfic mostra el percentatge de fitxers pels quals s'ha almenys un bon resultat. En algunes ocasions els resultats bons retornats per *Bing* o *Yahoo* han estat superiors en nombre, però com es pot veure el cercador *Google* ofereix major cobertura amb resultats sobre més articles diferents.




Figura 6.2: Comparació del número de consultes necessàries abans de trobar bons resultats


En el segon gràfic veiem que pel que fa a les consultes, el número de cerques que hem de fer per començar a obtenir bons resultats disminueix a mesura que es fan servir més paraules. De totes maneres, tal i com ja s'ha dit a la secció 3.2, és bo que ens saltem les primeres consultes per evitar cercar amb el títol de l'article i anar directament al resum o *abstract*.



## 6.2 Generació de *wrappers*

Per provar aquesta part del sistema, hem creat conjunts de pàgines web amb informació d'articles diferents i amb la referència corresponent. Cada grup inclou només pàgines corresponents a la mateixa biblioteca digital i per cadascun d'ells conjunts hem importat les referències i n'hem generat els *wrappers* pels diferents camps.

Les mostres no són gaire significatives, però ens donen una idea per poder quantificar com de bé funciona el sistema dins l'entorn pel qual està pensat. Les proves d'aquesta secció corresponen a les puntuacions rebudes durant l'avaluació dels *wrappers* i permeten marcar un ordre d'elecció inicial a l'hora d'extreure referències. Com que de moment encara no hem fet proves amb pàgines que no s'han emprat per la generació (ho farem a la propera secció), els gràfics no indiquen la correctesa dels resultats dels *wrappers* sinó la *confiança* que tenim en que funcionin. Tal i com ja s'ha dit, els camps obligatoris que han de contenir les referències a articles són: *author*, *title*, *journal* i *year* i són amb els que ens centrarem.



El primer gràfic permet comparar el número de *wrappers* obtinguts per cadascun dels camps per diferents biblioteques i utilitzant 4 exemples al generar. Tal i com es pot veure a la llegenda, els hem classificat en diferents grups de confiança, depenent de la puntuació rebuda a l'avaluar-los

amb aquests mateixos 4 exemples i s’han omès aquells que no han funcionat en cap cas. Aquí ens interessa veure, sobretot, si hi ha almenys un *wrappers* de confiança *Cc*. Quan n’hi més d’un, solen indicar que les dades estan repetides dins la pàgina i que, per tant, hi ha diverses formes de poder-les extreure. En el cas del camp *title* de la biblioteca *acm*, el títol es troba tant dins de l’etiqueta `<title>` com dins el `<body>` de la pàgina font.

El gràfic també mostra dos casos pels quals no s’ha obtingut cap *wrapper* que hagi funcionat per tots els exemples: el camp *author* de la biblioteca *InformaWorld* i el camp *year* d’*Ideas*. Amb una ullada ràpida a les regles generades n’hi ha prou per veure que es tracta de problemes de generalització. Pel cas del camp corresponent a l’any, les expressions regulars de les dues *regex rules* són:

```
"Handle\:\ RePEc\:\ tov\:\ dsiess\:\ v\:\ 3\:\ y\:\ (.*)"
"Handle\:\ RePEc\:\ (?:.*) af\:\ (?:.*) v\:\ (?:.*) \:\ y\:\ (.*)"
```

Llistat 6.1: Configuració de la validació de referències



Aquest és el problema que s’ha descrit a la secció 5.2.2 al parlar de la generació d’expressions regulars. Els patrons inicials han estat massa diferents com per fusionar-los i s’ha acabat amb regles massa específiques. Si ho corregim manualment, l’expressió resultant seria:

```
"Handle\:\ RePEc\:\ (?:.*) \:\ y\:\ (.*)"
```

Llistat 6.2: Configuració de la validació de referències

Aquí queda plasmada ara la importància d’escollir bons exemples per la generació de regles. A l’apèndix D hi ha la mateixa gràfica, però corresponent als *wrappers* obtinguts utilitzant només 2 exemples, tot i que els resultats són similars.

A part d’aquesta vista dels resultats més detallada, les gràfiques 6.3 i 6.4 també mostren el percentatge de biblioteques provades per les quals s’han obtingut *wrappers* de confiança, depenent del número d’exemples utilitzats per la generació. La línia fosca correspon al percentatge de les biblioteques digitals per les quals hem obtingut almenys un *wrapper* de confiança màxima, la línia més clara indica el mateix percentatge, però corresponent al següent interval de confiança. Finalment, la línia discontinua representa la suma de les dues anteriors.


Figura 6.3: Cobertura dels *wrappers* pel camp *journal*Figura 6.4: Cobertura dels *wrappers* pel camp *year*

El camp corresponent a l'any és interessant perquè moltes de les pàgines que hem provat contenen múltiples aparicions del valor que busquem, però no sempre descrivint l'any de publicació, sinó la data de revisió, la data a partir de la qual l'article es troba a Internet, *copyright*, etc. Aquest tipus de confusions també són habituals quan, a més de la informació de l'article, les pàgines inclouen llistats amb les citacions o referències a d'altres publicacions. No obstant, a mesura que comencem a tenir més exemples l'avaluació ens permetrà escollir aquells que realment són vàlids.

Altres camps pels quals es té més dificultat per generar *wrappers* són aquells el valor dels quals consisteix en números petits, com ara el número de volum o de revista *number*. El motiu és el mateix, hi ha moltes aparicions del mateix valor, però que no fan referència al camp que busquem.

### 6.3 Extracció de referències

Anem a veure ara com de bé ho fan els *wrappers* generats a la secció anterior per les mateixes biblioteques i camps. Disposem de conjunts de pàgines corresponents articles diferents i les referències en BibT<sub>E</sub>X que ens serviran de control per saber en quins casos s'ha encertat i en quins no. Com que en aquest punt els resultats són més interessants, hem inclòs els dos gràfics aquí mateix. Per començar ens fixarem amb la correctesa dels camps extrets amb regles generades a partir de dos exemples:



Es considera que el valor extret és:


- *Correcte*: Quan el valor obtingut coincideix exactament amb el de la referència de control.

- *Parcialment correcte*: Si el valor extret conté el valor de control a més d'altra informació. Per exemple, un dels valors extrets pel camp *journal* de la biblioteca *ACM* és: *ACM Computing Surveys (CSUR)* mentre que el valor de la referència de control és *ACM Computing Surveys*. Tot i que aquests casos es podrien considerar correctes, s'ha decidit generar els gràfics aplicant les regles de classificació de forma estricta.
- *Incorrecte*: Qualsevol altre cas.

Veiem que utilitzant dos exemples hi ha hagut força problemes, tots deguts a que les regles són massa específiques com per cobrir altres pàgines:

- Com ja hem anticipat a la secció anterior, un dels camps amb més problemes ha estat l'any, que no s'ha pogut extreure correctament en tres de les quatre biblioteques que es mostren per culpa que no s'ha escollit bé l'element HTML que realment conté aquesta informació.
- Els autors de la biblioteca *SpringerLink* no s'han extret del tot bé en cap dels casos, per culpa a que els separadors de les *separator rules* no són prou genèrics.
- Per últim, els resultats de la biblioteca *InformaWorld* són pèssims per culpa de combinacions dels problemes anteriors.

Anem a veure què passa quan fem les mateixes proves amb els *wrappers* generats a partir de quatre exemples diferents:



El nombre d'extraccions correctes ha augmentat força, i els valors marcats com a *parcialment correctes* corresponen a situacions que realment es podrien considerar vàlides. En canvi, segueixen havent-hi problemes amb els anys i els autors de la biblioteca *InformaWorld*. Podem mirar de corregir-los manualment.

Respecte als autors d'*InformaWorld* no s'ha sabut identificar correctament l'element HTML que els conté. Només canviant l'expressió regular de l'inici de la *path rule*, per ajudar a escollir l'element correcte, passem a extreure els autors de forma correcta per a tots els casos.

```
[".*", ["div", {"id": "metahead"}, 0], ...
```

```
["Authors?:\ (.*)", ["div", {"id": "metahead"}, 0], ...
```


Pel que fa a l'any de publicació, el problema consisteix, una vegada més, en una expressió regular massa específica:

```
"Published\ in \:Accounting\ Education\,\ Volume\ \ 1(?:.*)\
\,\ Issue\ \ (?:.*)\ \&\ (?:.*)\ \ (?:.*)\ (.*)\ \,\
pages\ (?:.*)\ \-\ "
```

```
"\ (\d{4})\ \,\ pages\ "
```

Un cop fetes aquestes correccions, si tornem a executar les proves per extreure les referències, obtenim un 100% d'encerts pels quatre camps que hem tractat.

Correctesa dels camps extrets (wrappers corregits)



Els resultats d'extracció dels camps que no es mostren als gràfics (e.g. número de volum, pàgines) són molt similars als que acabem de veure. El número de revista i volum tenen problemes similars als de l'any, en canvi, altres menys comuns com ara l'ISSN una taxa d'encert molt alta.

## Capítol 7

# Conclusions i Treball Futur

7.1 Objectius Assolits

7.2 Possibles Millores

# Bibliografia

- [GBL98] C. Lee Giles, Kurt D. Bollacker, and Steve Lawrence. Citeseer: an automatic citation indexing system. In *International Conference on Digital Libraries*, pages 89–98. ACM Press, 1998.
- [Mil09] Evan Miller. How not to sort by average rating. <http://www.evanmiller.org/how-not-to-sort-by-average-rating.html>, 2009.
- [Pyta] DiffliB - helpers for computing deltas. <http://docs.python.org/library/difflib.html>.
- [Pytb] Regular expression operations in python. <http://docs.python.org/library/re.html>.
- [RM88] John Ratcliff, W. and David Metzener. Pattern matching: The gestalt approach. *Dr. Dobbs's Journal*, page 46, 1988.
- [Sod99] Stephen Soderland. Learning information extraction rules for semi-structured and free text. *Machine Learning*, 34(1):233–272, 1999.



## Apèndix A

# Biblioteques utilitzades

Per una banda fen servir els següents mòduls de la biblioteca estàndar. No són els únics que utilitzem, però sí els que ofereixen funcionalitats més interessants:

- RE: Ofereix la possibilitat de treballar amb expressions regulars i amb una sintaxi molt rica. L'hem fet servir àmpliament a tot el sistema.
- SimpleJSON: L'hem utilitzat per dos objectius diferents: llegir fitxers en format JSON i per serialitzar i desserialitzar objectes *Python* a l'emmagatzemar-los a la base de dades. Els objectes serialitzats utilitzant aquest mòdul tenen la característica que són llegibles per les persones. Per exemple, el resultat de serialitzar un diccionari és: `'{"clau01": 4, "clau03": 15, "clau02": 8}'`
- DiffLib: Ens permet fer *string matching* i obtenir llistes de blocs coincidents així com un índex de similaritat entre dues cadenes de caràcters. L'utilitzem a l'hora de generar regles automàticament, per tal de decidir quan hem de fusionar regles i com ho hem de fer.
- ConfigParser: Mòdul que ens permet llegir el fitxer de configuració de l'aplicació al qual hi ha definits els diferents paràmetres que guien l'aplicació.

També fem ús de les biblioteques següent:

- XGoogle: Es tracta d'una biblioteca força senzilla escrita per Peteris Krumins que ens facilita les cerques a Internet. L'objectiu del creador era oferir la possibilitat de cercar a *Google* sense les limitacions de la API oficial, que només deixa obtenir un màxim de 32 resultats. Nosaltres l'hem ampliat per poder obtenir resultats de *Google Scholar* i posteriorment, també per utilitzar les APIs oficials JSON de *Google*, *Bing* i *Yahoo*.
- BeautifulSoup: Es tracta d'un *parser* d'HTML i XML desenvolupat per Leonard Richardson que genera arbres sintàctics els quals podem consultar segons les etiquetes HTML, els atributs, o bé el text que contenen.
- *Parser* de BIB<sub>T</sub>E<sub>X</sub>: Es tracta d'un *parser* escrit per Raphael Ritz pel projecte Bibliograph.parsing. El fem servir per obtenir els diferents camps de les referències a l'hora d'importar-les a l'aplicació i a l'extreure-les mitjançant *reference wrappers* (veure 4.1.1) per tal de poder-les validar.

## *Apèndix A. Biblioteques utilitzades*

- *SQLAlchemy*: És un ORM per *Python* que facilita el treball amb la base de dades. A més, ofereix una capa d'abstracció que permet utilitzar la base de dades de forma independent a la tecnologia. Per exemple, nosaltres fem servir *SQLite*, però en teoria fer un canvi del sistema gestor de la base de dades sense haver de tocar res més.
- *PyQt*: Es tracta d'una biblioteca en *Python* que embolcalla el framework per la creació d'interfícies gràfiques *Qt*.

## Apèndix B

# Diagrames

En aquest apèndix es mostren alguns diagrames que poden ajudar a entendre una mica millor el context i funcionament de l'aplicació.

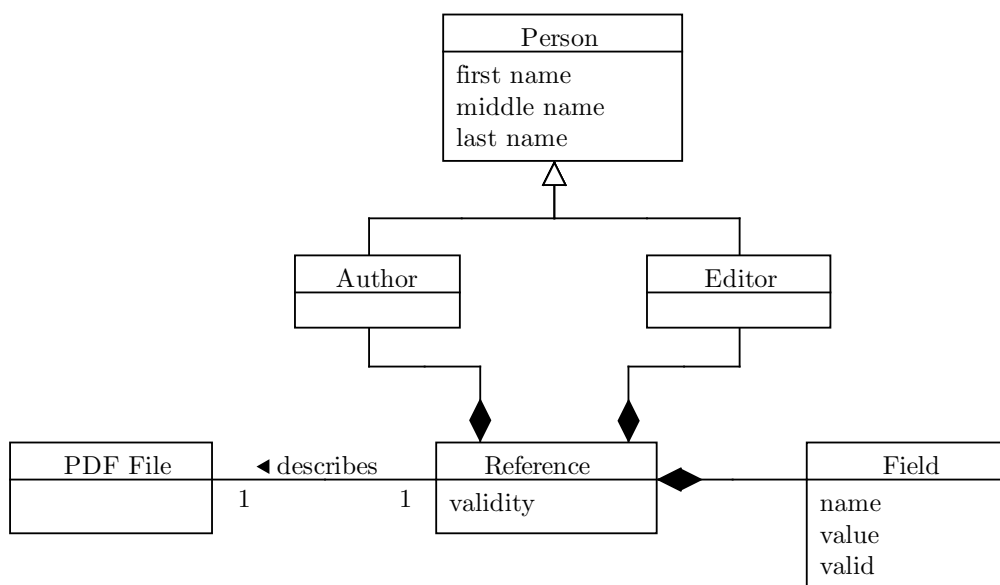


Figura B.1: Model de domini respecte a referències




Figura B.2: Model de dominil dels *wrappers*

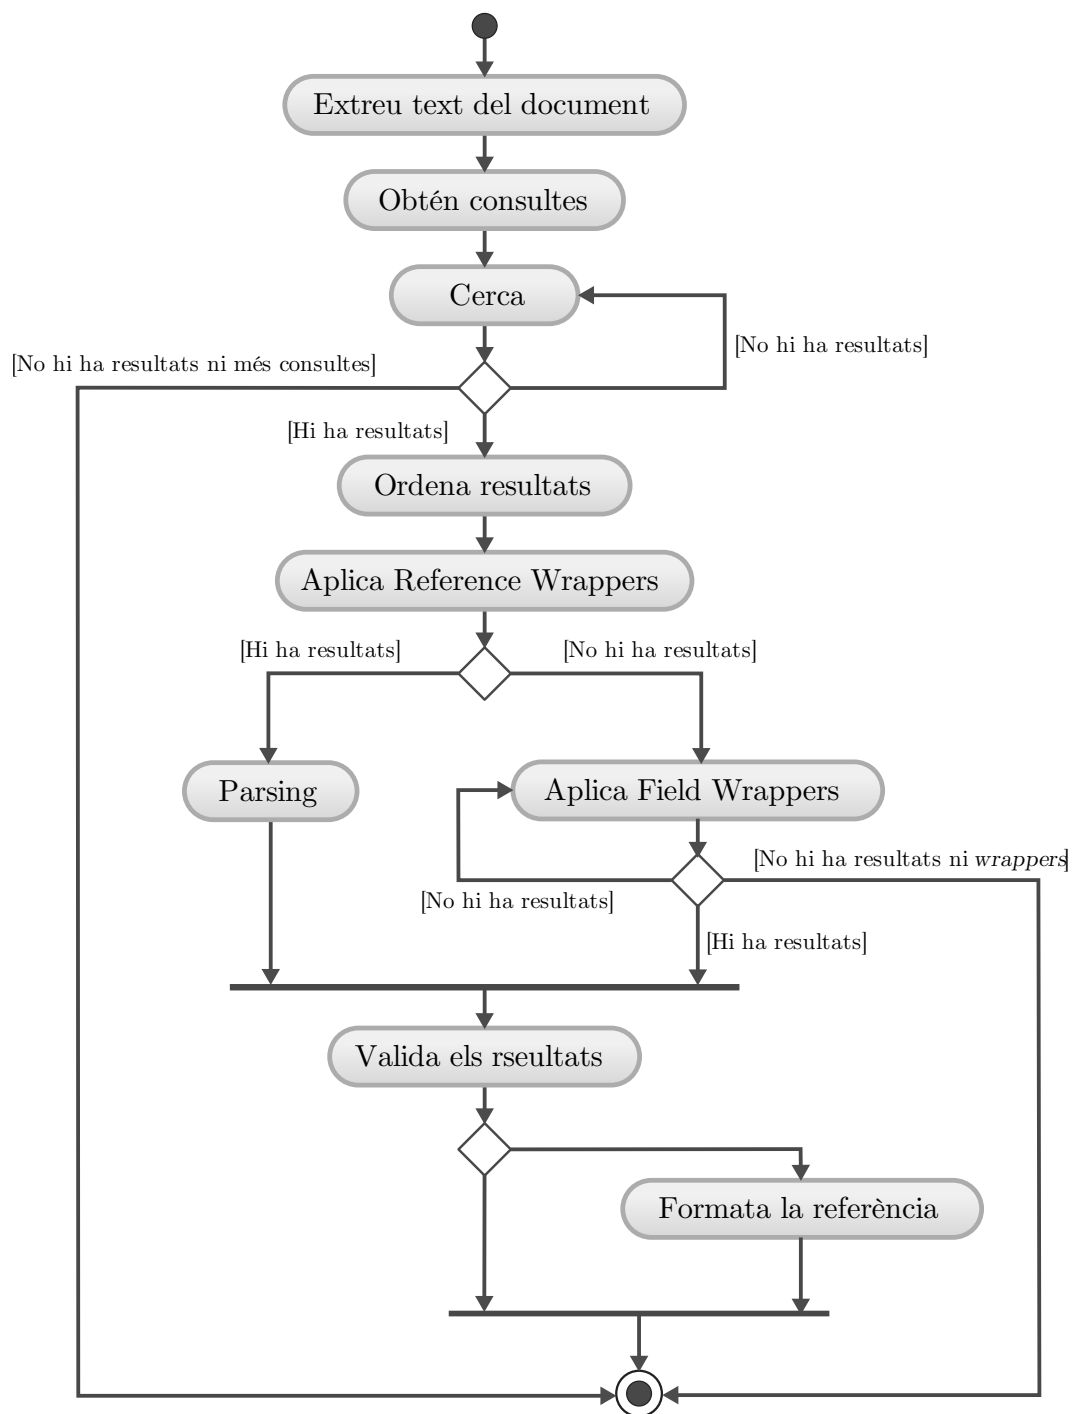


Figura B.3: Diagrama d'activitat per a l'extracció de referències

Apèndix C

**Extracció Contingut PDF**

## Apèndix D

# Resultats dels tests

A continuació es mostren els resultats complets de totes les proves realitzades a la nostra aplicació. L'explicació d'aquests números s'explica al capítol 6.

### D.1 Generació de *wrappers*

A continuació es mostren els gràfics de la cobertura dels *wrappers* generats per altres camps que no s'han tractat a la secció 6.2.

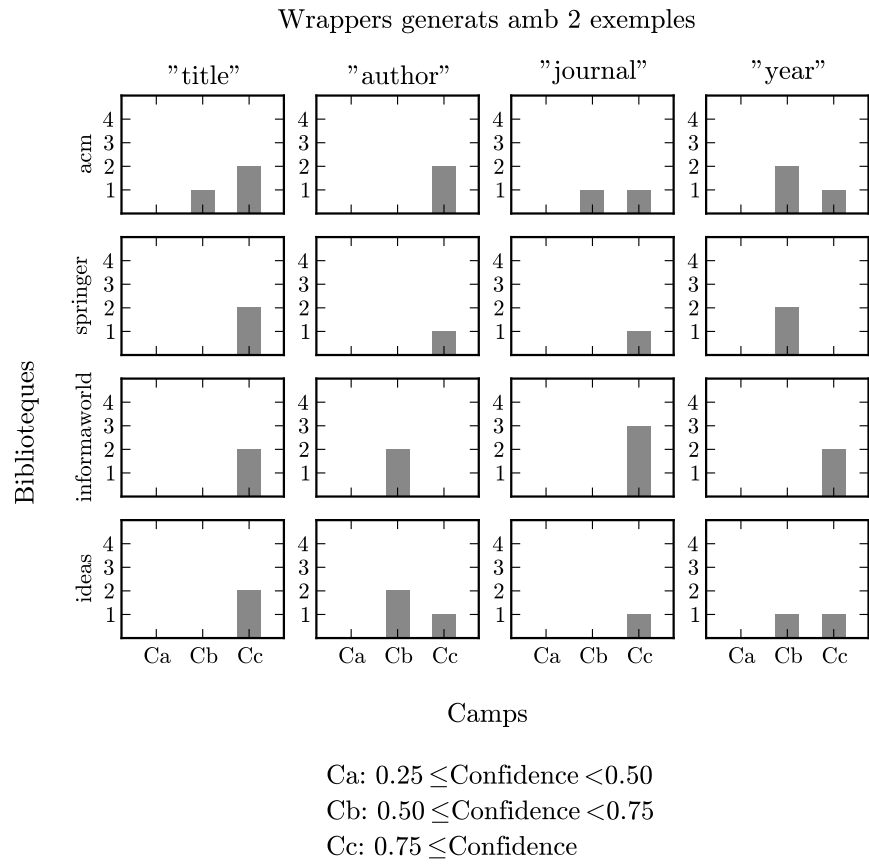



Figura D.1: Nombre de *Wrappers* generats utilitzant 2 exemples i agrupats per confiança





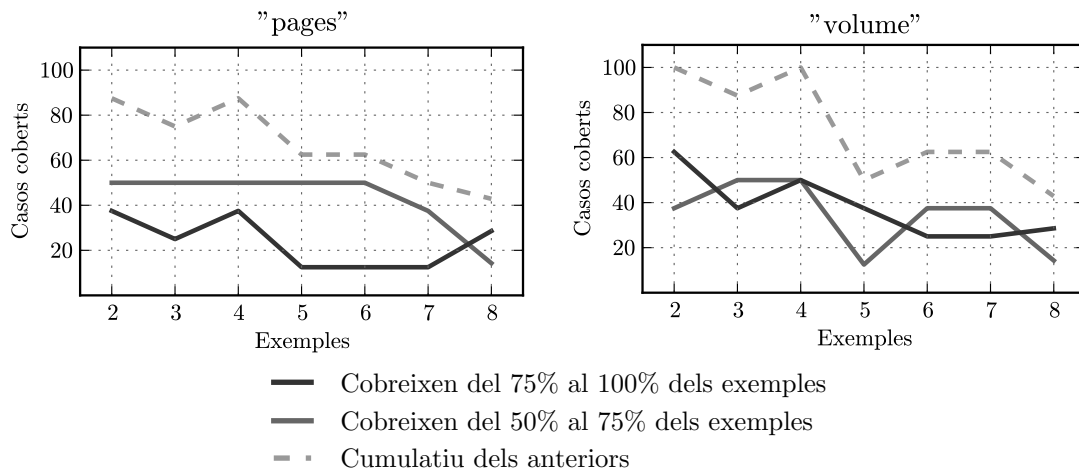


Figura D.2: Cobertura dels *wrappers* generats




Figura D.3: Temps mitjà per la generació dels *wrappers* d'un únic camp

## Apèndix E

# Manual d'usuari

### E.1 Referències




Figura E.1: Importa referències

Quan es clica comença el procés d'importació i es mostra la finestra. Per

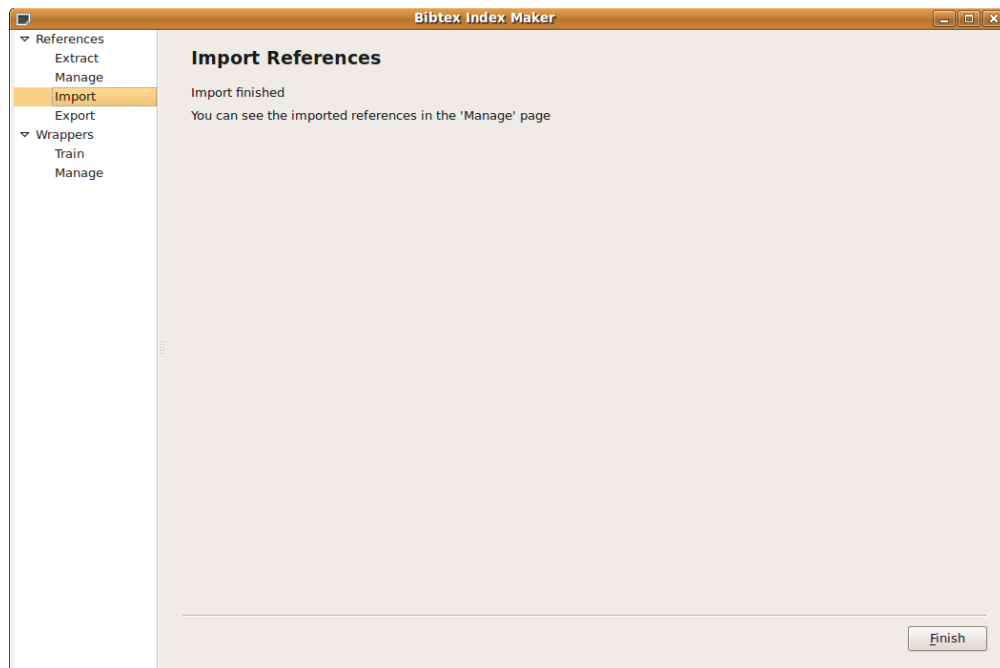


Figura E.2: Un cop s'han importat les referències




Figura E.3: Maneig de referències

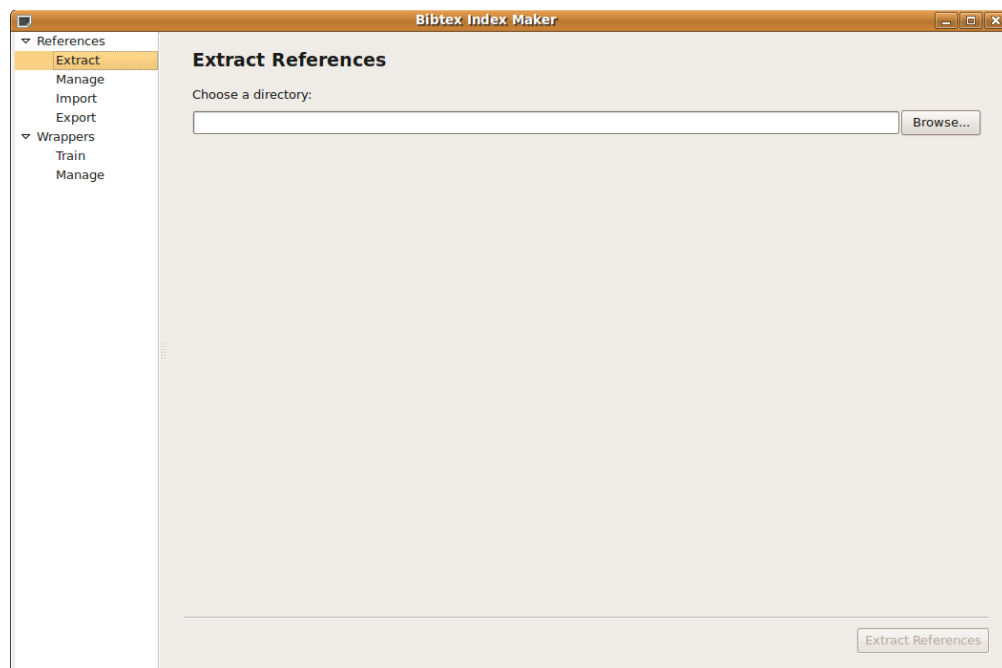


Figura E.4: Extreu referències

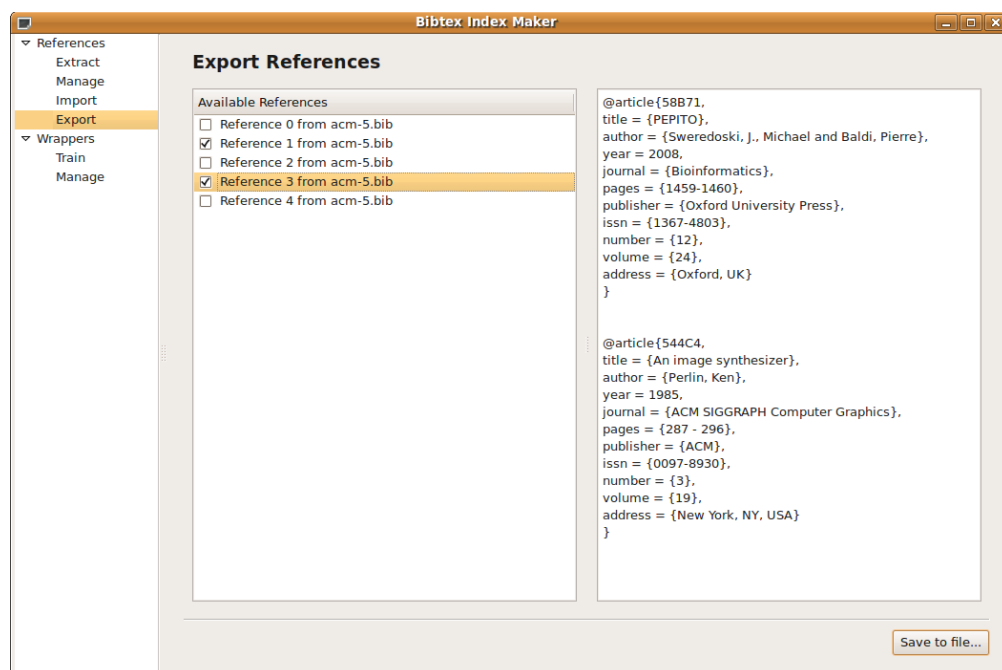


Figura E.5: Exporta referències

## E.2 *Wrappers*

Per poder extreure les referències, primer cal que tinguem *wrappers* entrenats per les biblioteques digitals que més ens interessin. Per fer-ho, podem seleccionar l'opció *Train* del menú de l'aplicació i se'ns mostrarà la vista següent.

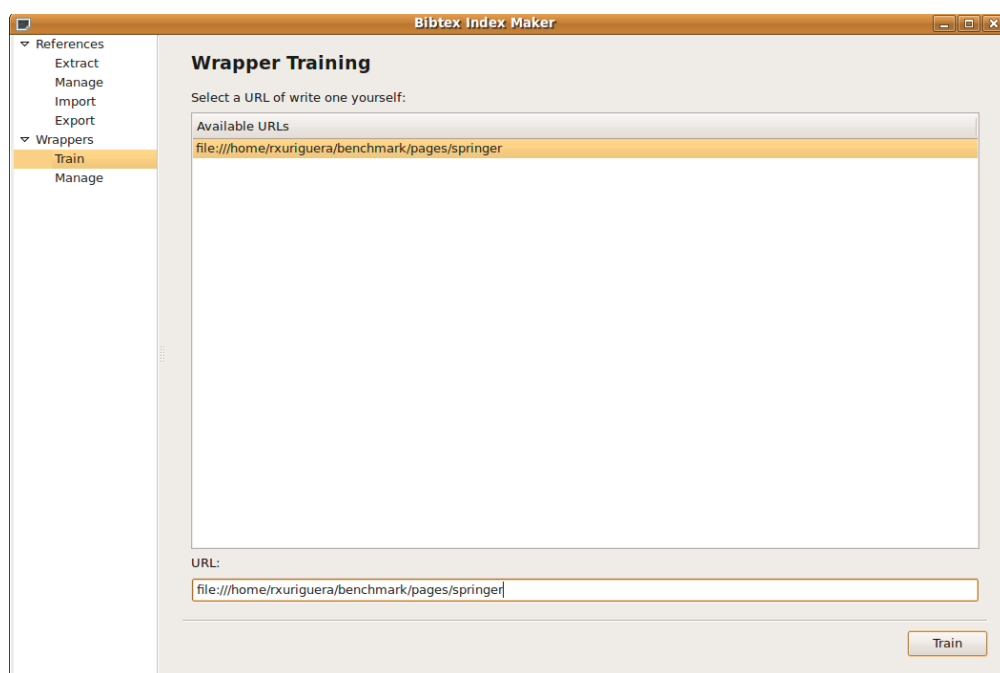


Figura E.6: Entrenament de *wrappers*

Un cop hem generat els *wrappers*, podem veure'ls i modificar-los a partir de l'opció *manage*, que ens porta a l'editor següent. Des d'aquí es poden realitzar les operacions CRUD per gestionar les col·leccions, *wrappers* i les regles.

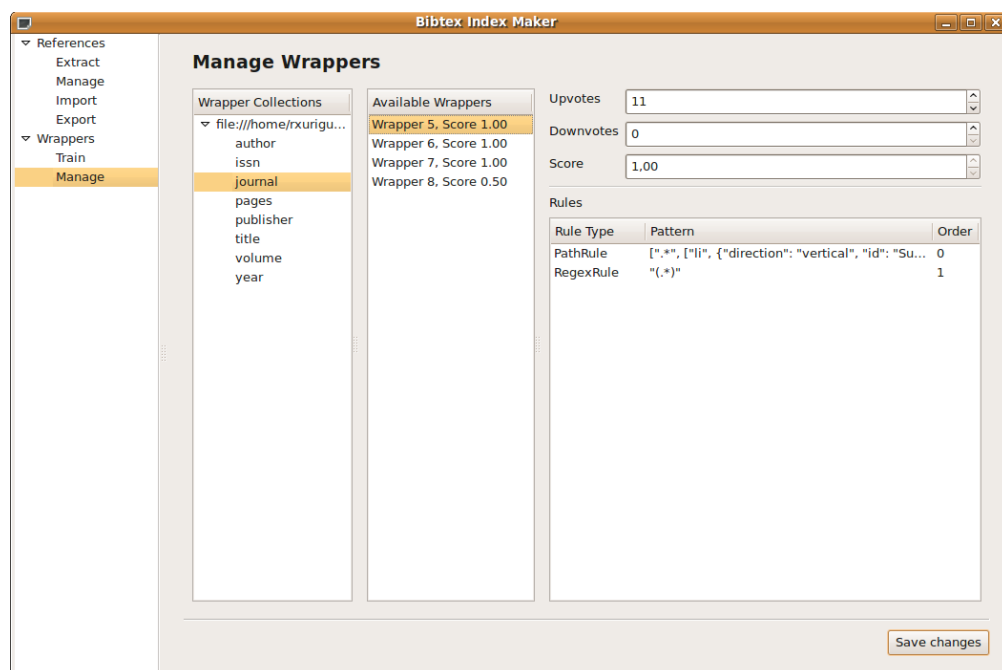


Figura E.7: Gestió de *wrappers*

